


APRENDIZAJE NO SUPERVISADO

# Clustering Jerárquico

Cómo un algoritmo construye un árbol de grupos, fusión a fusión.

[Nombre del presentador] · [Curso o evento] · [Fecha]



# Lo que vamos a ver

1

## *¿Qué es?*

La idea de una jerarquía de grupos.

2

## *Cómo funciona*

El algoritmo, los enlaces y el dendrograma.

3

## *Quién lo creó*

Autores clave, de 1948 a hoy.

4


## *En la práctica*

scikit-learn, resultados y lecciones.

¿QUÉ ES?


# Una jerarquía, no una sola partición

## *k-means y similares*



Devuelve **una** partición. Hay que fijar **k** antes de empezar.

## *Clustering jerárquico*



Devuelve **todas** las particiones anidadas. Eliges **k** después, cortando el árbol.

# Dos direcciones posibles


## Aglomerativo · AGNES

de abajo hacia arriba · el más usado



## Divisivo · DIANA

de arriba hacia abajo · heurístico



# *Solo necesita dos ingredientes*

$d(x, y)$

## *Distancia entre puntos*

Euclidiana, Manhattan, coseno... Define qué significa “parecerse”.

Escala tus variables antes.

$D(A, B)$


## *Criterio de enlace*

Cómo medir la distancia entre dos **grupos** a partir de sus puntos.

Es la decisión más importante.


CÓMO FUNCIONA

# El algoritmo en 4 pasos



Pseudocódigo completo: [docs/pseudocodigo.md](#) · diagrama 1 en [docs/diagramas.md](#)


# Cuatro criterios de enlace



## Single

El par **más cercano**.


Sigue formas alargadas.  
Riesgo: efecto cadena.



## Complete

El par **más lejano**.


Grupos compactos. Riesgo:  
outliers.



## Average

El **promedio** de todas las  
parejas.

Término medio, más robusto al  
ruido.



## Ward

El menor **aumento de  
varianza**.

Grupos esféricos. Solo  
euclidiana.

# Ejemplo a mano con 6 puntos


| Paso | Single        | Altura | Ward          | Altura |
|------|---------------|--------|---------------|--------|
| 1    | p0 + p1 → C6  | 0.135  | p0 + p1 → C6  | 0.135  |
| 2    | p4 + p5 → C7  | 0.170  | p4 + p5 → C7  | 0.170  |
| 3    | p2 + p3 → C8  | 0.184  | p2 + p3 → C8  | 0.184  |
| 4    | C6 + C8 → C9  | 0.414  | C6 + C7 → C9  | 0.746  |
| 5    | C7 + C9 → C10 | 0.420  | C8 + C9 → C10 | 0.754  |

¡En el paso 4 los enlaces discrepan!

**Single** une {p0, p1} con {p2, p3}, porque p1 y p2 están cerca.

**Ward** une {p0, p1} con {p4, p5}, la fusión que menos aumenta la varianza.

# Cómo leer un dendrograma



**El eje vertical es lo único métrico**

La altura es la distancia a la que se fusionaron los grupos.

**El orden horizontal no significa nada**

p5 y p0 son vecinas, pero solo se unen en la raíz.

**Cortar = elegir  $k$**

Cada rama que cruza la línea es un cluster.

# ¿Cuántos clusters? Dos pistas

## SALTO EN LA ALTURA

7x

Pasar de 3 a 2 clusters cuesta 13.0; pasar de 4 a 3 cuesta 1.85. Un salto así marca el corte natural.

## COEFICIENTE DE SILUETA

0.846

Es el máximo, y se alcanza en  $k = 3$ . Mide qué tan compactos y separados quedan los grupos.

*Ambas pistas coinciden:  $k = 3$ .*

QUIÉN LO CREÓ

# Muchas manos, una misma idea

1948

**Sørensen**

Ecología vegetal. Antecedente del enlace complete.

1951

**Florek y otros**

Escuela de Wrocław. Formalizan el enlace single.

1958

**Sokal y Michener**

Enlace average (UPGMA), estudiando abejas.

1963

**Sokal y Sneath**

Principles of Numerical Taxonomy.

1963

**Joe H. Ward Jr.**

Fusionar minimizando la pérdida de información.

1967

**Lance y Williams**

Una fórmula que unifica todos los enlaces.

1967

**Stephen C. Johnson**


Dendrogramas como ultramétricas (Bell Labs).

1990

**Kaufman y Rousseeuw**

AGNES y DIANA llegan al software.

# De la taxonomía a scikit-learn



Métodos · Teoría · Algoritmos eficientes · Hoy. Diagrama 8 en [docs/diagramas.md](https://docs.diagramas.md)

EN LA PRÁCTICA

# El flujo del notebook

## 1 · Datos

make\_blobs, 150 puntos

## 2 · Escalar

StandardScaler

## 3 · Jerarquía

linkage con Ward

## 4 · Dendrograma

con línea de corte

## 5 · Elegir $k$

salto y silueta

## 6 · Modelo

AgglomerativeClustering

## 7 · Evaluar

silueta, cofenética, ARI

## 8 · Comparar

4 enlaces, blobs y lunas

```
AgglomerativeClustering(n_clusters=3, linkage="ward").fit_predict(X_esc)
```

# Resultados

Blobs · Ward ·  $k = 3$

| Métrica                | Valor |
|------------------------|-------|
| Silueta                | 0.846 |
| Correlación cofenética | 0.976 |
| ARI con grupos reales  | 1.000 |

Grupos bien separados: los 4 enlaces dan el mismo resultado.

Lunas ·  $k = 2$

| Enlace   | ARI  | Silueta |
|----------|------|---------|
| single   | 1.00 | 0.38    |
| complete | 0.49 | 0.49    |
| average  | 0.61 | 0.46    |
| ward     | 0.69 | 0.45    |

Solo single separa bien las lunas, y tiene la silueta más baja.

## LECCIÓN CLAVE

*No existe un criterio de enlace universalmente mejor.*

Elige según la forma que esperas en tus datos, compara varios y no confíes en una sola métrica.

# Ventajas y desventajas

## + A favor

- No exige fijar  $k$  de antemano.
- El dendrograma es fácil de explicar.
- Admite cualquier distancia.
- Determinista: sin semilla aleatoria.

## - En contra

- Memoria  $O(n^2)$ : hasta decenas de miles de puntos.
- Las fusiones son irreversibles.
- Muy sensible al criterio de enlace.
- Sin `predict()` para datos nuevos.

# Todo está en el repositorio

## Pseudocódigo

<docs/pseudocodigo.md>

Algoritmo, Lance–Williams, ejemplo a mano.

## Diagramas

<docs/diagramas.md>

8 diagramas en Mermaid para Excalidraw.

## Notebook

[notebooks/clustering\\_jerarquico.ipynb](notebooks/clustering_jerarquico.ipynb)

Implementación guiada con scikit-learn.

## Repositorio

<didier-hierarchical-clustering-101>

README con instrucciones de ejecución.

# ¿Preguntas?